

Probabilità e Statistica¹

Isadora Antoniano-Villalobos

isadora.antoniano@unive.it

Laurea in Informatica

(Data science/ Tecnologie e scienze dell'informazione)

Università Ca' Foscari di Venezia

Anno accademico 2023/2024

¹Materiale didattico redatto da: Isadora Antoniano-Villalobos & Federica Giummolè

Alcune variabili aleatorie continue

Distribuzione uniforme

Distribuzione uniforme

Immaginiamo che X sia una variabile che può assumere qualsiasi valore nell'intervallo (a, b) , indifferentemente. La sua densità di probabilità è allora costante nell'intervallo (a, b) e nulla al di fuori:



$$f(x) = \begin{cases} \frac{1}{b-a} & x \in (a, b) \\ 0 & \text{altrove} \end{cases}$$

X è una variabile aleatoria **uniforme** e si scrive $X \sim U(a, b)$.

A partire dalla densità si può trovare la funzione di ripartizione:

$$F(x) = \int_a^x \frac{1}{b-a} dy = \frac{x-a}{b-a}; \quad x \in (a, b)$$

Distribuzione uniforme



E' facile verificare che

$$\mathbb{E}[X] = \frac{a+b}{2}, \quad \text{Var}[X] = \frac{(b-a)^2}{12}.$$

Distribuzione normale

Distribuzione normale

Una variabile aleatoria X ha **distribuzione normale** o gaussiana, indicato $X \sim N(\mu, \sigma^2)$, se la sua funzione di densità ha la forma


$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp \left\{ -\frac{1}{2} \left(\frac{x - \mu}{\sigma} \right)^2 \right\}, \quad x \in \mathbb{R}, \mu \in \mathbb{R}, \sigma > 0.$$

✚ **Johann Friedrich Carl Gauss (1777–1855):**
matematico, astronomo e fisico tedesco, che ha dato contributi determinanti in analisi matematica, teoria dei numeri, statistica, calcolo numerico, geometria differenziale, geodesia, geofisica, magnetismo, elettrostatica, astronomia e ottica. Talvolta definito *il più grande matematico della modernità*. ([Wikipedia](#))



Carl Friedrich Gauss

Distribuzione normale

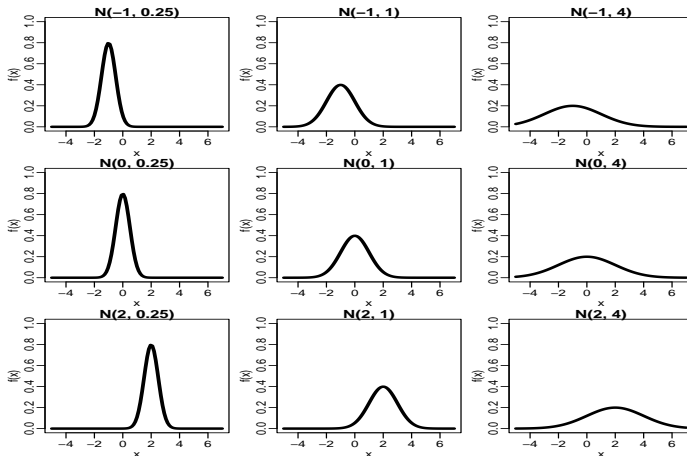


Si può dimostrare che

$$\mathbb{E}[X] = \mu, \quad \text{Var}[X] = \sigma^2.$$

Distribuzione normale

I parametri μ e σ^2 della normale non cambiano la forma a campana della densità ma determinano la sua posizione e concentrazione:



Distribuzione normale

La funzione di ripartizione di una v.a. normale non si può calcolare in forma esplicita. Ma utilizzando **R** (o un qualsiasi pacchetto statistico) si può oggi calcolare numericamente:

Esempio: $X \sim N(-1, 4)$

→ $\mathbb{P}[X \leq 1] = 0.8413$

> `pnorm(q=1,mean=-1,sd=2)`

[1] 0.8413447

→ $\mathbb{P}[0 \leq X \leq 1] = 0.1499$

> `pnorm(q=1,mean=-1,sd=2)-pnorm(q=0,mean=-1,sd=2)`

[1] 0.1498823

Distribuzione normale

Standardizzazione

La variabile $Z \sim N(0, 1)$ viene anche chiamata **normale standard** e la sua f.r. si denota con la Φ . Alla normale standard si riducono tutte le altre normali mediante la **standardizzazione**:

$$X \sim N(\mu, \sigma^2) \quad \Rightarrow \quad Z = \frac{X - \mu}{\sigma} \sim N(0, 1)$$

Una volta (e ancora adesso a volte...), per calcolare delle probabilità per qualsiasi variabile aleatoria normale si usavano le **tavole della distribuzione normale standard** (Le trovate nel vostro libro: date un'occhiata!). Queste bastano grazie alla standardizzazione:

$$\mathbb{P}[a < X < b] = \mathbb{P}\left[\frac{a - \mu}{\sigma} < Z < \frac{b - \mu}{\sigma}\right] = \Phi\left(\frac{b - \mu}{\sigma}\right) - \Phi\left(\frac{a - \mu}{\sigma}\right).$$

Distribuzione normale

Esempio:

$$X \sim N(-1, 4) \Rightarrow Z = \frac{X + 1}{2} \sim N(0, 1)$$

$$\rightarrow \mathbb{P}[X \leq 1] = \mathbb{P}\left[Z \leq \frac{1+1}{2}\right]$$

```
> pnorm(q=1, mean=-1, sd=2)
```

```
[1] 0.8413447
```

```
> pnorm(q=(1+1)/2, mean=0, sd=1)
```

```
[1] 0.8413447
```

$$\rightarrow \mathbb{P}[0 \leq X \leq 1] = \mathbb{P}\left[\frac{0+1}{2} \leq Z \leq \frac{1+1}{2}\right]$$

```
> pnorm(q=1, mean=-1, sd=2) - pnorm(q=0, mean=-1, sd=2)
```

```
[1] 0.1498823
```

```
> pnorm(q=(1+1)/2, mean=0, sd=1) - pnorm(q=(0+1)/2, mean=0, sd=1)
```

```
[1] 0.1498823
```

Distribuzione normale

Esempio: Una macchina produce tubi di diametro X (in mm). Il diametro X potrebbe essere modellizzato con una distribuzione normale di media μ mm e varianza σ^2 mm². Supponiamo che per contratto i tubi debbano essere di diametro d mm più o meno un margine di specifica di ϵ mm. Si noti che d non è necessariamente uguale a μ perché la macchina potrebbe essere centrata su valori leggermente diversi.


- Calcolare la probabilità che un generico tubo sia difettoso (cioè fuori specifica, o non conforme).

👉 Sia $p = \mathbb{P}[\text{"X è difettoso"}]$. Allora,

$$\begin{aligned} p &= \mathbb{P}[(X < d - \epsilon) \cup (d + \epsilon < X)] = \mathbb{P}[X < d - \epsilon] + \mathbb{P}[d + \epsilon < X] \\ &= \int_{-\infty}^{d-\epsilon} \frac{1}{\sqrt{2\pi}\sigma} \exp\left\{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2\right\} dx + \int_{d+\epsilon}^{+\infty} \frac{1}{\sqrt{2\pi}\sigma} \exp\left\{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2\right\} dx. \end{aligned}$$

Distribuzione normale

Dati μ , σ , T e ϵ siamo in grado di calcolare p (in R, per esempio, con il comando `pnorm`).



- Calcolare la probabilità che due tubi su 10 siano difettosi.

☝ Sia

S_{10} = “numero di tubi difettosi su 10”

la variabile che conta il numero di successi in 10 prove indipendenti in cui ogni prova può risultare un successo (difettoso o non conforme) con probabilità

$$p = \mathbb{P}[\text{“X è difettoso”}]$$

Distribuzione normale

o un insuccesso (conforme) con probabilità $1 - p$. Allora

$$S_{10} \sim \text{Bin}(10, p)$$

e la probabilità che due tubi su 10 siano difettosi è data dalla formula della funzione di probabilità binomiale:

$$\mathbb{P}[S_{10} = 2] = \binom{10}{2} p^2 (1 - p)^8.$$

Esercizio: Fare i calcoli con $\mu = 3$, $\sigma = 0.09$, $d = 2.94$ e $\epsilon = 0.18$.

👉 $p = 0.0950$, $\mathbb{P}[S_{10} = 2] = 0.1827$

Approssimazione normale per la binomiale


Quando n è “grande”, allora la funzione di ripartizione di una v.a. binomiale di parametri n e p si può approssimare con la funzione di ripartizione di una normale di parametri $\mu = np$ e $\sigma^2 = np(1 - p)$:

Approssimazione normale per la binomiale

$$\text{Bin}(n, p) \approx \text{N}(np, np(1 - p)).$$

- L'approssimazione viene utilizzata nella pratica quando $np(1 - p) \geq 10$.
- Questa è una conseguenza del **teorema del limite centrale** (che studieremo più avanti)

Approssimazione normale per la binomiale



Approssimazione normale per la binomiale

Esempio: Un certo virus danneggia un file con probabilità 0.35, indipendentemente dagli altri file. Il virus attacca una cartella con 2400 file. Qual è la probabilità che vengano danneggiati fra gli 800 e gli 850 file (inclusi)?

👍 Sia X la variabile che conta il numero di file danneggiati su 2400. Allora $X \sim \text{Bin}(2400, 0.35)$ e la probabilità richiesta è:

$$\mathbb{P}[800 \leq X \leq 850] = \sum_{k=800}^{850} \binom{2400}{k} 0.35^k (1-0.35)^{2400-k} = 0.632893.$$

Calcolata con **R**:

```
> pbinom(850,2400,0.35)-pbinom(799,2400,0.35)
[1] 0.632893
```


Approssimazione normale per la binomiale

Possiamo anche approssimare X con una normale con parametri

$$\mu = 2400 \cdot 0.35 = 840$$

$$\sigma = \sqrt{2400 \cdot 0.35 \cdot (1 - 0.35)} = \sqrt{546} = 23.36664.$$

Otteniamo, con la cosiddetta **correzione per continuità**:

$$\begin{aligned}\mathbb{P}[800 \leq X \leq 850] &= \mathbb{P}[\mathbf{799.5} < X < \mathbf{850.5}] \\ &\approx \Phi\left(\frac{850.5 - 840}{23.36664}\right) - \Phi\left(\frac{799.5 - 840}{23.36664}\right) \\ &= \Phi(0.4493586) - \Phi(-1.73324) = 0.631887.\end{aligned}$$

Calcolata con **R**:

```
> pnorm((850.5-840)/23.36664)-pnorm((799.5-840)/23.36664)
[1] 0.631887
```

Distribuzione gamma

Distribuzione gamma

Si dice che X ha **distribuzione gamma** di parametri $\alpha > 0$ e $\lambda > 0$, e si scrive $X \sim \text{Ga}(\alpha, \lambda)$, se la sua densità di probabilità è della forma

$$f(x) = \begin{cases} \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x} & x \in (0, \infty) \\ 0 & \text{altrove} \end{cases}$$


dove $\Gamma(\alpha) = \int_0^\infty x^{\alpha-1} e^{-x} dx$ è la **funzione gamma**.

Si può dimostrare che

$$\mathbb{E}[X] = \frac{\alpha}{\lambda}, \quad \text{Var}[X] = \frac{\alpha}{\lambda^2}.$$

Distribuzione gamma

La densità della gamma al variare di α e λ cambia sia forma che posizione:



Distribuzione gamma

Esempio: Se X è una v.a. gamma di media 4 e varianza 4, allora

$$\alpha = 4 \quad \text{e} \quad \lambda = 1 .$$

👍 Si può allora calcolare (integrando ripetutamente per parti)

$$\begin{aligned}\mathbb{P}[X < 4] &= \int_0^4 \frac{e^{-x} x^3}{6} dx \\ &= \frac{1}{6} \left[-(x^3 + 3x^2 + 6x + 6)e^{-x} \right]_0^4 = \\ &= 0.567 .\end{aligned}$$

👍 In questo caso il calcolo esplicito è stato possibile poiché α è un numero intero e

$$\Gamma(4) = \int_0^{\infty} x^{4-1} e^{-x} dx = (4-1)! = 6 .$$

Distribuzione gamma

In generale, usando **R** si possono calcolare probabilità legate a variabili con distribuzione gamma:

➔ Per $X \sim \text{Ga}(1.5, 0.5)$, $\mathbb{P}[X \leq 1] = 0.19874804$

```
> pgamma(q=1, shape=1.5, rate=0.5)
```

```
[1] 0.198748
```

➔ Per $X \sim \text{Ga}(7.5, 1)$, $\mathbb{P}[X \geq 7.2] = 0.49543391$

```
> 1-pgamma(q=7.2, shape=7.5, rate=1)
```

```
[1] 0.4954339
```

Si può anche valutare la funzione gamma:

➔ $\Gamma(4) = 6$ $\Gamma(7.5) = 1871.254$

```
> gamma(4)
```

```
[1] 6
```

```
> gamma(7.5)
```

```
[1] 1871.254
```

Distribuzione esponenziale

Distribuzione esponenziale

Un caso particolare di distribuzione gamma con $\alpha = 1$ è la **distribuzione esponenziale**, $X \sim \text{Exp}(\lambda)$.

La sua densità è

$$f(x) = \begin{cases} \lambda e^{-\lambda x} & x \in (0, \infty) \\ 0 & \text{altrove} \end{cases}$$

e la sua funzione di ripartizione si può calcolare in forma esplicita:

$$F(x) = \begin{cases} 0 & x < 0 \\ 1 - e^{-\lambda x} & x \geq 0 \end{cases}$$

Distribuzione esponenziale

Evidentemente,

$$\mathbb{E}[X] = \frac{1}{\lambda} \quad \text{e} \quad \text{Var}[X] = \frac{1}{\lambda^2} .$$

La distribuzione esponenziale si usa per modellare tempi di attesa. Ad esempio:

- ❶ il tempo che passa fra l'arrivo di un treno in stazione e il successivo;
- ❷ la vita di un certo componente elettronico di un'automobile;
- ❸ la lunghezza fra due difetti consecutivi di una fibra ottica.

Distribuzione esponenziale

Mancanza di memoria

Se $X \sim \text{Exp}(\lambda)$, allora

$$\begin{aligned}\mathbb{P}[X > t + s | X > t] &= \frac{\mathbb{P}[X > t + s]}{\mathbb{P}[X > t]} \\ &= \mathbb{P}[X > s] .\end{aligned}$$

Questa proprietà si dimostra tenendo conto che

$$\mathbb{P}[X > x] = e^{-\lambda x} , \quad x > 0 .$$

- La distribuzione esponenziale è l'unica distribuzione continua con la proprietà di **mancanza di memoria** (come la geometrica fra le distribuzioni discrete).

Distribuzione esponenziale

Esempio: Il tecnico di un laboratorio dell'università in un'ora installa un certo *software* in media su 30 pc. Assumendo che il tempo di installazione su ogni pc segua una distribuzione esponenziale, vogliamo calcolare la probabilità che il tecnico impieghi più di 5 minuti per installare il *software* nel prossimo pc.

👍 $X = \text{tempo di attesa in ore} \sim \text{Exp}(30)$

$$\Rightarrow \mathbb{P}[X > 1/12] = e^{-30/12}$$

👍 $X = \text{tempo di installazione in minuti} \sim \text{Exp}(1/2)$

$$\Rightarrow \mathbb{P}[X > 5] = e^{-5/2}$$

Il processo di Poisson

Ricordiamo: La variabile di Poisson viene spesso utilizzata per i conteggi.

➔ **Esempio:** i messaggi in arrivo nella mia casella di posta elettronica sono in media 12 ogni 10 minuti. Inoltre si può supporre che la variabile che conta i messaggi in arrivo in un intervallo di 10 minuti abbia distribuzione di Poisson:

$$X_{10} = \text{"numero messaggi in 10 min."} \sim \mathcal{P}(12)$$

Possiamo allora calcolare probabilità del tipo:

$$\begin{aligned}\mathbb{P}[\text{meno di 6 messaggi fra le 11:00 e le 11:10}] &= \\ &= \mathbb{P}[X_{10} < 6] = 0.02 .\end{aligned}$$

➔ E se fossimo interessati a intervalli di tempo di durata diversa da 10 minuti?

Il processo di Poisson

Processo di Poisson

Il processo di Poisson è una successione di variabili aleatorie $\{X_t\}_{t \geq 0}$, con distribuzione di Poisson il cui parametro dipende dall'indice t :

$$X_t \sim \mathcal{P}(\lambda \times t).$$

Si usa per contare il numero di manifestazioni di un fenomeno di interesse in un qualsiasi intervallo di tempo di ampiezza t , quando il numero medio di queste manifestazioni dipende soltanto dall'ampiezza (e non dalla posizione) dell'intervallo considerato.

Possiamo allora scrivere:

- X_t = "n. di eventi in un intervallo di tempo t "
- λ = "n. medio di eventi nell'unità di tempo".

Il processo di Poisson

Esempio: Il numero di messaggi in arrivo alla mia casella di posta elettronica segue un processo di Poisson nel tempo, con una media di 12 messaggi ogni 10 minuti.

👉 Se scegliamo il minuto come unità di misura del tempo, abbiamo:

$$\lambda = \text{"n. medio di messaggi in 1 min."} = 12/10$$

$$X_t = \text{"n. di messaggi in } t \text{ min."} \sim \text{Po} \left(\frac{12}{10} t \right)$$

Possiamo allora calcolare, ad esempio,

$$\begin{aligned} \mathbb{P}[\text{più di 20 messaggi in mezz'ora}] &= \\ &= \mathbb{P}[X_{30} > 20] = 1 - \mathbb{P}[X_{30} \leq 20], \end{aligned}$$

$$\text{con } X_{30} \sim \text{Po} \left(\frac{12}{10} 30 \right) = \text{Po}(36).$$

Il processo di Poisson

Relazione con la distribuzione esponenziale: Associata ad ogni processo di Poisson c'è una variabile aleatoria esponenziale che misura il **tempo fra due manifestazioni successive** del fenomeno in questione:

- X_t = “n. di eventi in un intervallo di tempo t ”

$$X_t \sim \text{Po}(\lambda t)$$

- T = “tempo trascorso fra due eventi successivi”

$$T \sim \text{Exp}(\lambda)$$

Il processo di Poisson

Esempio: Per l'esempio dei messaggi in arrivo alla casella di posta elettronica:

$$\begin{aligned}\mathbb{P}[\text{nessun messaggio in 15 minuti}] &= \\ &= \mathbb{P}[X_{15} = 0] = \frac{(12/10 \times 15)^0}{0!} e^{-12/10 \times 15} = e^{-18} \\ &= \mathbb{P}[T > 15] = e^{-12/10 \times 15} = e^{-18},\end{aligned}$$

dove $T \sim \text{Exp}(12/10)$ misura il tempo che passa fra l'arrivo di due messaggi successivi.